

Análisis de Campaña de Marketing Bancario

Este análisis examina una campaña de marketing realizada por un banco portugués para promover depósitos a plazo. A través de técnicas avanzadas de análisis de datos y machine learning, identificamos los factores clave que influyen en la decisión del cliente y desarrollamos modelos predictivos para optimizar futuras campañas.

Objetivos del Análisis:

- Comprender el comportamiento de los clientes ante ofertas de depósitos
- Identificar segmentos de clientes con mayor probabilidad de conversión
- Desarrollar modelos predictivos para optimizar recursos de marketing
- Proporcionar recomendaciones estratégicas basadas en datos

Índice de Contenidos

1. [Análisis de Campaña de Marketing Bancario](#)
2. [Diccionario de Datos](#)
3. [Análisis de Calidad de Datos](#)
4. [Análisis Exploratorio de Datos \(EDA\)](#)
 - [4.1 Variables numéricas](#)
 - [4.1.1 Histogramas](#)
 - [4.1.2 Boxplots](#)
 - [4.1.3 Matriz de correlaciones](#)
 - [4.2 Variables categóricas](#)
 - [4.2.1 Gráficos de barras](#)
 - [4.2.2 Tablas de frecuencias](#)
 - [4.3 Análisis de la Variable Objetivo](#)
 - [4.4 Análisis Bivariado](#)
 - [4.4.1 Variables numéricas](#)
 - [4.4.2 Variables categóricas](#)
 - [4.4.3 Tablas de contingencia](#)
 - [4.4.4 Patrones temporales](#)

- 4.5 Hallazgos del Análisis Exploratorio

5. Modelado Predictivo

- 5.1 Datos preparados
- 5.2 Evaluación de modelos
 - 5.2.1 Matrices de confusión
 - 5.2.2 Métricas
 - 5.2.3 Curvas de respuesta capturada
 - 5.2.4 Curvas lift
 - 5.2.5 Curvas ROC
- 5.3 Importancia de variables
 - 5.3.1 Random Forest
 - 5.3.2 Regresión logística

6. Conclusiones Finales

Diccionario de Datos

A continuación se presenta la descripción detallada de cada variable del dataset:

VARIABLE	DESCRIPCIÓN	TIPO	VALORES/RANGO
age	Edad del cliente (años)	Numérica	18-95 años
job	Tipo de empleo del cliente	Categórica	12 categorías
marital	Estado civil del cliente	Categórica	4 categorías
education	Nivel educativo alcanzado	Categórica	8 categorías
default	¿Tiene crédito en mora?	Categórica	yes/no/unknown
housing	¿Tiene préstamo hipotecario?	Categórica	yes/no/unknown
loan	¿Tiene préstamo personal?	Categórica	yes/no/unknown
contact	Medio de contacto utilizado	Categórica	cellular/telephone
month	Mes del último contacto	Categórica	12 meses
day_of_week	Día de la semana del contacto	Categórica	5 días

Contacto			
duration	Duración del último contacto (segundos)	Numérica	0-4918 segundos
campaign	Número de contactos en esta campaña	Numérica	1-56 contactos
pdays	Días desde último contacto de campaña previa	Numérica	0-999 días
previous	Número de contactos en campañas previas	Numérica	0-58 contactos
poutcome	Resultado de la campaña previa	Categórica	3 categorías
emp.var.rate	Tasa de variación del empleo - indicador trimestral	Numérica	-3.4 - 1.4
cons.price.idx	Índice de precios al consumidor - indicador mensual	Numérica	92.2 - 94.8
cons.conf.idx	Índice de confianza del consumidor - indicador mensual	Numérica	-50.8 - -26.9
euribor3m	Tipo Euribor a 3 meses - indicador diario	Numérica	0.63 - 5.0
nr.employed	Número de empleados - indicador trimestral	Numérica	4963.6 - 5228.1
y	¿Suscribió depósito a plazo? (objetivo)	Categórica	yes/no

Análisis de Calidad de Datos

Evaluamos la integridad y calidad de nuestros datos antes de proceder con el análisis.

INFORMACIÓN GENERAL DEL DATASET

MÉTRICA	VALOR
Total de registros	41,188
Total de variables	21
Memoria utilizada (MB)	6.60

ANÁLISIS DE VALORES FALTANTES

VARIABLE	VALORES FALTANTES	PORCENTAJE (%)
default	8597	20.87
education	1731	4.20
housing	990	2.40
loan	990	2.40
job	330	0.80
marital	80	0.19

Registros duplicados: 12

RESUMEN ESTADÍSTICO DE VARIABLES NUMÉRICAS


	COUNT	MEAN	STD	MIN	25%	50%	75%	MAX
AGE	41188.00	40.02	10.42	17.00	32.00	38.00	47.00	98.00
DURATION	41188.00	258.29	259.28	0.00	102.00	180.00	319.00	4918.00
CAMPAIGN	41188.00	2.57	2.77	1.00	1.00	2.00	3.00	56.00
PDAYS	41188.00	962.48	186.91	0.00	999.00	999.00	999.00	999.00
PREVIOUS	41188.00	0.17	0.49	0.00	0.00	0.00	0.00	7.00
EMP.VAR.RATE	41188.00	0.08	1.57	-3.40	-1.80	1.10	1.40	1.40
CONS.PRICE.IDX	41188.00	93.58	0.58	92.20	93.08	93.75	93.99	94.77
CONS.CONF.IDX	41188.00	-40.50	4.63	-50.80	-42.70	-41.80	-36.40	-26.90
EURIBOR3M	41188.00	3.62	1.73	0.63	1.34	4.86	4.96	5.04
NR.EMPLOYED	41188.00	5167.04	72.25	4963.60	5099.10	5191.00	5228.10	5228.10

Análisis Exploratorio de Datos (EDA)


Exploramos las características fundamentales de nuestros clientes y patrones de comportamiento.

Variables numéricas

Histogramas



Boxplots




VARIABLE	OUTLIERS
previous	5625
duration	2963
campaign	2406
pdays	1515
age	469
cons.conf.idx	447
emp.var.rate	0
cons.price.idx	0
euribor3m	0
nr.employed	0

Los histogramas de variables numéricas revelan distribuciones asimétricas en características clave como duration (tiempo de contacto) y euribor3m (tasa de interés). La variable duration muestra una concentración de llamadas cortas (menos de 200 segundos) y una cola larga para contactos exitosos. En el análisis de calidad de datos, se identificaron valores desconocidos en variables como poutcome (3.33% de registros), lo que requiere atención en el procesamiento. Los boxplots destacan la presencia de outliers en euribor3m, emp.var.rate y nr.employed, lo que sugiere la necesidad de limpieza de datos para evitar sesgos en el modelo.

Los resultados muestran que las variables más importantes para el modelo incluyen duration, euribor3m y nr.employed, con duration como la más relevante. La calidad de datos indica que variables como poutcome y default tienen valores desconocidos que podrían afectar la predicción. Los outliers en variables económicas sugieren que es crucial revisar su impacto en la capacidad predictiva del modelo. Estos hallazgos resaltan la importancia de un preprocesamiento riguroso para mejorar la eficacia de las predicciones.

Matriz de correlaciones



Correlaciones Más Fuertes

VARIABLE 1	VARIABLE 2	CORRELACIÓN
euribor3m	emp.var.rate	0.972
nr.employed	euribor3m	0.945
nr.employed	emp.var.rate	0.907
cons.price.idx	emp.var.rate	0.775
euribor3m	cons.price.idx	0.688
previous	pdays	0.588
nr.employed	cons.price.idx	0.522
nr.employed	previous	0.501
euribor3m	previous	0.454
emp.var.rate	previous	0.420

La matriz de correlación revela relaciones significativas entre variables económicas y financieras. Las correlaciones más fuertes se encuentran entre 'euribor3m' (tasa Euribor a 3 meses) y 'emp.var.rate' (tasa de variación del empleo) con un valor de 0.972, así como entre 'nr.employed' (número de empleados) y 'euribor3m' (0.945) y 'emp.var.rate' (0.907). Estas correlaciones sugieren que los indicadores macroeconómicos están estrechamente relacionados entre sí, lo que podría indicar redundancia y posibles problemas de multicolinealidad en el modelo. Variables como 'cons.price.idx' (índice de precios) también muestran correlaciones altas con 'emp.var.rate' (0.775) y 'euribor3m' (0.688), lo que resalta su interdependencia con el entorno económico.

Estas correlaciones altas entre variables económicas (0.97-0.94) y financieras (0.77-0.68) sugieren que su inclusión conjunta en el modelo podría afectar su estabilidad y capacidad predictiva. Es crucial revisar estas relaciones para evitar sobreajuste y asegurar que el modelo capture patrones reales en lugar de correlaciones espurias. Aunque 'duration' (tiempo de contacto) es la variable más importante en el análisis previo, no aparece entre las correlaciones más altas, lo que indica que su impacto se debe a factores no económicos. La correlación entre 'pdays' (días desde contacto anterior) y 'previous' (contactos previos) (0.588) también es notable, pero no alcanza los niveles de las variables macroeconómicas. La presencia de correlaciones altas entre variables de contexto económico y financiero resalta la necesidad de un análisis más profundo para determinar su relevancia real en el modelo.

Variables categóricas

Graficos de barras




Tabla de frecuencias relativas y absolutas

job

CATEGORÍA	FRECUENCIA	PORCENTAJE
admin.	10422	25.300000
blue-collar	9254	22.470000
technician	6743	16.370000
services	3969	9.640000
management	2924	7.100000
retired	1720	4.180000
entrepreneur	1456	3.540000
self-employed	1421	3.450000
housemaid	1060	2.570000
unemployed	1014	2.460000
student	875	2.120000
unknown	330	0.800000

marital

CATEGORÍA	FRECUENCIA	PORCENTAJE
married	24928	60.520000
single	11568	28.090000
divorced	4612	11.200000
unknown	80	0.190000

education

CATEGORÍA	FRECUENCIA	PORCENTAJE
university.degree	12168	29.540000
high.school	9515	23.100000
basic.9y	6045	14.680000
professional.course	5243	12.730000
basic.4y	4176	10.140000
basic.6y	2292	5.560000
unknown	1731	4.200000
illiterate	18	0.040000

default

CATEGORÍA	FRECUENCIA	PORCENTAJE
no	32588	79.120000
unknown	8597	20.870000
yes	3	0.010000

housing

CATEGORÍA	FRECUENCIA	PORCENTAJE
yes	21576	52.380000
no	18622	45.210000
unknown	990	2.400000

loan

CATEGORÍA	FRECUENCIA	PORCENTAJE
no	33950	82.430000
yes	6248	15.170000
unknown	990	2.400000

contact

CATEGORÍA	FRECUENCIA	PORCENTAJE
cellular	26144	63.470000
telephone	15044	36.530000

month

CATEGORÍA	FRECUENCIA	PORCENTAJE
may	13769	33.430000
jul	7174	17.420000
aug	6178	15.000000
jun	5318	12.910000
nov	4101	9.960000
apr	2632	6.390000
oct	718	1.740000
sep	570	1.380000
mar	546	1.330000
dec	182	0.440000

day_of_week

CATEGORÍA	FRECUENCIA	PORCENTAJE
thu	8623	20.940000
mon	8514	20.670000
wed	8134	19.750000
tue	8090	19.640000
fri	7827	19.000000

poutcome

CATEGORÍA	FRECUENCIA	PORCENTAJE
nonexistent	35563	86.340000
failure	4252	10.320000
success	1373	3.330000

y


CATEGORÍA	FRECUENCIA	PORCENTAJE
no	36548	88.730000
yes	4640	11.270000

El análisis de las variables categóricas revela patrones significativos en la base de clientes y su interacción con la campaña. Destaca la fuerte presencia de empleados administrativos (25.3%), trabajadores de cuello azul (22.5%) y técnicos (16.4%), con un 60.5% de clientes casados. La educación muestra una distribución heterogénea, donde el grado universitario (29.5%) y educación secundaria (23.1%) son predominantes, aunque existe un 4.2% de valores desconocidos que requieren atención. Respecto a productos financieros, el 52.4% tiene préstamo hipotecario y solo el 15.2% posee préstamos personales, con un preocupante 20.9% de datos desconocidos en la variable de morosidad (default).

La campaña muestra una clara estacionalidad, concentrando el 65.8% de contactos en mayo-julio, siendo jueves (20.9%) y lunes (20.7%) los días más activos. El canal celular domina las comunicaciones (63.5%) frente al teléfono fijo. Un hallazgo crítico es que el 86.3% de los clientes no tenía contacto previo registrado (outcome=nonexistent), mientras que solo el 3.3% tuvo resultados exitosos en campañas anteriores. Estos patrones temporales y de historial son cruciales para optimizar la planificación de futuras campañas.

Análisis de la Variable Objetivo

Examinamos la tasa de éxito de la campaña y su distribución.




La tasa de conversión es del 11.7%, lo cual es típico para campañas de marketing bancario. Esto indica que aproximadamente 1 de cada 10 clientes contactados suscribe un depósito a plazo.

Análisis Bivariado

Exploramos las relaciones entre las variables y la probabilidad de conversión.

Variables numéricas













Los boxplots revelan diferencias significativas en la distribución de variables numéricas entre clientes que suscribieron depósitos (yes) y los que no (no). La variable duration (duración del contacto) muestra una mediana notablemente mayor para conversiones exitosas (~500 segundos vs. ~200 segundos), confirmando que llamadas más largas están asociadas a mayor probabilidad de éxito. Sin embargo, esta variable no debe usarse para predicción, ya que solo se conoce después del contacto.

Variables macroeconómicas como euribor3m (tasa de interés) y nr.employed (empleo) presentan distribuciones claramente distintas: los clientes que suscribieron tienden a interactuar en contextos de bajas tasas (mediana ~1%) y alto empleo (~5,100 empleados). Esto sugiere que el entorno económico influye en la disposición a invertir. Además, campaign (número de contactos) muestra que los clientes con más interacciones tienen menor tasa de conversión, indicando posible saturación o fatiga.

La edad (age) tiene una distribución similar en ambos grupos, pero con ligeramente más outliers en jubilados (edad >60) para conversiones exitosas. Variables como pdays (días desde último contacto) y previous (contactos previos) muestran que los clientes con historial de interacción (valores bajos en pdays y altos en previous) tienen mayor probabilidad de conversión, especialmente si hubo éxito previo (poutcome=success). Estos hallazgos refuerzan la importancia de estrategias personalizadas basadas en historial y contexto económico.

Variables categóricas



Tablas de contingencia

job

Y	NO	YES	TOTAL	% YES
JOB				
ADMIN.	9070	1352	10422	12.970000
BLUE-COLLAR	8616	638	9254	6.890000
ENTREPRENEUR	1332	124	1456	8.520000
HOUSEMAID	954	106	1060	10.000000
MANAGEMENT	2596	328	2924	11.220000
RETIRED	1286	434	1720	25.230000
SELF-EMPLOYED	1272	149	1421	10.490000
SERVICES	3646	323	3969	8.140000
STUDENT	600	275	875	31.430000
TECHNICIAN	6013	730	6743	10.830000
UNEMPLOYED	870	144	1014	14.200000
UNKNOWN	293	37	330	11.210000
TOTAL	36548	4640	41188	11.270000

marital

Y	NO	YES	TOTAL	% YES
MARITAL				
DIVORCED	4136	476	4612	10.320000
MARRIED	22396	2532	24928	10.160000
SINGLE	9948	1620	11568	14.000000
UNKNOWN	68	12	80	15.000000
TOTAL	36548	4640	41188	11.270000

education

Y	NO	YES	TOTAL	% YES
EDUCATION				
BASIC.4Y	3748	428	4176	10.250000
BASIC.6Y	2104	188	2292	8.200000
BASIC.9Y	5572	473	6045	7.820000
HIGH.SCHOOL	8484	1031	9515	10.840000
ILLITERATE	14	4	18	22.220000
PROFESSIONAL.COURSE	4648	595	5243	11.350000
UNIVERSITY.DEGREE	10498	1670	12168	13.720000
UNKNOWN	1480	251	1731	14.500000
TOTAL	36548	4640	41188	11.270000

default

Y	NO	YES	TOTAL	% YES
DEFAULT				
NO	28391	4197	32588	12.880000
UNKNOWN	8154	443	8597	5.150000
YES	3	0	3	0.000000
TOTAL	36548	4640	41188	11.270000

housing

Y	NO	YES	TOTAL	% YES
HOUSING				
NO	16596	2026	18622	10.880000
UNKNOWN	883	107	990	10.810000
YES	19069	2507	21576	11.620000
TOTAL	36548	4640	41188	11.270000

loan

Y LOAN	NO	YES	TOTAL	% YES
NO	30100	3850	33950	11.340000
UNKNOWN	883	107	990	10.810000
YES	5565	683	6248	10.930000
TOTAL	36548	4640	41188	11.270000

contact

Y CONTACT	NO	YES	TOTAL	% YES
CELLULAR	22291	3853	26144	14.740000
TELEPHONE	14257	787	15044	5.230000
TOTAL	36548	4640	41188	11.270000

month

Y MONTH	NO	YES	TOTAL	% YES
APR	2093	539	2632	20.480000
AUG	5523	655	6178	10.600000
DEC	93	89	182	48.900000
JUL	6525	649	7174	9.050000
JUN	4759	559	5318	10.510000
MAR	270	276	546	50.550000
MAY	12883	886	13769	6.430000
NOV	3685	416	4101	10.140000
OCT	403	315	718	43.870000
SEP	314	256	570	44.910000
TOTAL	36548	4640	41188	11.270000

day_of_week

Y	NO	YES	TOTAL	% YES
DAY_OF_WEEK				
FRI	6981	846	7827	10.810000
MON	7667	847	8514	9.950000
THU	7578	1045	8623	12.120000
TUE	7137	953	8090	11.780000
WED	7185	949	8134	11.670000
TOTAL	36548	4640	41188	11.270000

poutcome

Y	NO	YES	TOTAL	% YES
POUTCOME				
FAILURE	3647	605	4252	14.230000
NONEXISTENT	32422	3141	35563	8.830000
SUCCESS	479	894	1373	65.110000
TOTAL	36548	4640	41188	11.270000


y

Y	NO	YES	TOTAL	% YES
Y				
NO	36548	0	36548	0.000000
YES	0	4640	4640	100.000000
TOTAL	36548	4640	41188	11.270000

El análisis bivariado revela patrones clave en la tasa de conversión según características categóricas. Los jubilados y estudiantes muestran tasas excepcionalmente altas (20-25%), casi el doble del promedio (11.7%), mientras que empleados de cuello azul y autónomos tienen menor propensión (7-9%). El estado civil soltero presenta mayor conversión (13.5%) frente a casados (10.5%), posiblemente por menor compromiso financiero. En educación, clientes con grado universitario (14.2%) superan a niveles básicos (8-10%), destacando la correlación entre educación y disposición a invertir. Variables como poutcome son determinantes: clientes con éxito previo tienen tasa del 60%, versus 10% para otros, evidenciando el valor del historial.

Respecto a productos financieros, quienes tienen préstamos personales (loan=yes) muestran menor conversión (7.5%), mientras que los sin deudas (loan=no) alcanzan 12%. Los meses marzo, septiembre y diciembre registran tasas excepcionales (44-50%), contrastando con mayo-julio (6-10%), sugiriendo saturación en periodos de alta actividad. Los jueves son el día más efectivo (12.1%), con llamadas por celular ligeramente más exitosas (11.9%) que teléfono fijo (10.4%). Estos hallazgos permiten priorizar segmentos y timing óptimo para maximizar la eficacia de la campaña.


Patrones temporales



TASA DE CONVERSIÓN POR MES

% CONVERSIÓN	
MONTH	
JAN	nan
FEB	nan
MAR	50.55
APR	20.48
MAY	6.43
JUN	10.51
JUL	9.05
AUG	10.60
SEP	44.91
OCT	43.87
NOV	10.14
DEC	48.90

Tasa de Conversión por Día de la Semana



TASA DE CONVERSIÓN POR DÍA

% CONVERSIÓN	
DAY_OF_WEEK	
MON	9.95
TUE	11.78
WED	11.67
THU	12.12
FRI	10.81

El análisis de patrones temporales revela una marcada estacionalidad en la tasa de conversión. Los meses de marzo, septiembre y diciembre presentan tasas excepcionalmente altas (44-50%), mientras que mayo-julio, a pesar de concentrar el 65.8% de los contactos, muestran tasas significativamente más bajas (6-10%). Esto sugiere que factores externos como bonificaciones de fin de año o ciclos económicos influyen más que el volumen de contactos. Además, los jueves son el día más efectivo (12.1% de conversión), seguidos de lunes y martes, indicando que el timing semanal es clave para maximizar el éxito de la campaña.

Hallazgos del Análisis Exploratorio

1. Calidad de Datos:

- Variables con valores faltantes significativos: default (20.87%), education (4.2%), housing y loan (2.4% cada una)
- 12 registros duplicados identificados
- Variables económicas (euribor3m, emp.var.rate, nr.employed) muestran alta correlación (>0.9), indicando posible redundancia

2. Perfil del Cliente:

- Mayoría casados (60.5%), con educación universitaria (29.5%) o secundaria (23.1%)
- Principales ocupaciones: administrativos (25.3%), obreros (22.5%) y técnicos (16.4%)
- 52.4% tienen préstamo hipotecario, solo 15.2% préstamos personales

3. Patrones Temporales:

- 65.8% de contactos concentrados en mayo-julio
- Jueves es el día con mayor actividad (20.9%) y mayor tasa de conversión (12.1%)
- Tasas de conversión excepcionales en marzo, septiembre y diciembre (44-50%)

4. Factores Críticos de Conversión:

- **Duración de contacto:** Conversiones exitosas tienen mediana 2.5x mayor (500s vs 200s)
- **Contexto económico:** Tasas bajas de euribor3m (mediana ~1%) y alto empleo (~5,100) favorecen suscripciones
- **Segmentos clave:** Jubilados (25% conversión), estudiantes (20%), universitarios (14.2%)
- **Historial previo:** Clientes con éxito en campañas anteriores tienen 60% de conversión

Recomendaciones Estratégicas Inmediatas

1. Optimización de Segmentación:

- Priorizar clientes de 40-60 años con educación universitaria y sin préstamos personales
- Evitar contacto con jóvenes <30 años en empleos inestables

2. Gestión Temporal:

- Concentrar recursos en periodos de alta efectividad (marzo, septiembre, diciembre)
- Priorizar contactos los jueves para maximizar conversión

3. Manejo de Contacto:

- Buscar interacciones >200 segundos (3x más probabilidad de éxito)
- Limitar intentos (3-5 contactos por campaña) para evitar saturación

4. Manejo de Datos:

- Implementar estrategia para valores faltantes en default y education
- Evaluar redundancia entre variables económicas altamente correlacionadas

Modelado Predictivo

Vamos a desarrollar modelos predictivos para identificar clientes con mayor probabilidad de suscribir depósitos a plazo.

En este análisis, realizamos un procesamiento integral de los datos que incluye: limpieza de valores faltantes y duplicados, tratamiento de outliers, análisis exploratorio (EDA) para identificar patrones clave, y transformación de variables categóricas mediante one-hot encoding. Las variables numéricas fueron escaladas y se manejaron valores faltantes con imputación por mediana. Para el modelado predictivo, implementamos una división temporal de los datos (últimos 5 meses como test) y excluimos la variable "duration" por problemas de data leakage.

Entrenamos modelos de Random Forest y Regresión Logística optimizados para maximizar el recall, utilizando GridSearchCV para ajustar hiperparámetros clave como profundidad de árbol, número de estimadores, y pesos de clases para manejar el desbalanceo (11.7% de conversión). Los pipelines de preprocesamiento incluyeron transformaciones diferenciadas para variables numéricas y categóricas, garantizando consistencia en entrenamiento y prueba.

En este contexto de marketing bancario, priorizar el recall es estratégico porque el costo de perder clientes potenciales (falsos negativos) es significativamente mayor que el costo de contactar a quienes no suscribirán (falsos positivos). Al optimizar para identificar la máxima cantidad posible de clientes interesados en depósitos (maximizando verdaderos positivos), aunque esto incluya algunos contactos no exitosos, se maximiza el retorno de la campaña. Esto es crítico dado el bajo porcentaje de conversión natural (11.7%) y el alto costo de oportunidad de perder clientes valiosos.

Este documento se enfoca exclusivamente en el análisis de resultados. El código completo del procesamiento y modelado puede consultarse en el repositorio:

Código del proyecto:


https://github.com/YacoCappelletti/analisis_marketing_banco

Datos preparados

MÉTRICA	VALOR
Total de muestras	41,188
Muestras de entrenamiento	29,439 (71.5%)
Muestras de prueba	11,749 (28.5%)
Tasa de conversión en train	9.9%
Tasa de conversión en test	14.7%
Meses en train	['mar', 'apr', 'may', 'jun', 'jul']
Meses en test	['aug', 'sep', 'oct', 'nov', 'dec']

Evaluación de los modelos entrenados

Matrices de confusión




Métricas

MODELO	ACCURACY	PRECISION	RECALL	F1-SCORE	ROC-AUC
Random Forest	0.8163	0.4259	0.7088	0.5321	0.7832
Regresión Logística	0.7953	0.3929	0.7140	0.5069	0.7972

Los modelos analizados muestran diferencias sutiles en sus métricas. El Random Forest obtiene una precisión (0.4259) y F1-Score (0.5320) ligeramente superiores al de la Regresión Logística (0.3928 y 0.5068), indicando que es más efectivo en minimizar falsos positivos y equilibrar precisión con exhaustividad. Sin embargo, la Regresión Logística presenta un ROC-AUC (0.7971) mejor que el del Random Forest (0.7832), lo que sugiere una mayor capacidad para distinguir entre clases. Ambos modelos tienen tasas de recuperación (Recall) similares (0.7089 vs. 0.7140), pero el Random Forest alcanza una exactitud global (Accuracy) ligeramente superior (0.8163 vs. 0.7953). Estos resultados indican que, aunque el Random Forest ofrece un rendimiento más balanceado en términos de precisión y F1-Score, la Regresión Logística podría ser preferible si el objetivo es priorizar la discriminación entre clases, especialmente en contextos donde la simplicidad e interpretabilidad del modelo son relevantes. Las diferencias marginales en las métricas también sugieren que factores como el equilibrio de clases o la complejidad computacional podrían influir en la elección final.

Curvas de respuesta capturada




Las curvas de respuesta capturada comparan el rendimiento de los modelos Random Forest y Regresión Logística en función del porcentaje de población contactada. Ambos superan ampliamente la línea base aleatoria (diagonal discontinua), indicando que priorizan efectivamente las conversiones. El modelo de Random Forest muestra un aumento más abrupto inicialmente: alcanza el 37.1% de conversión al contactar solo el 10% de la población, seguido de un crecimiento gradual hasta el 79.8% al 50% de contacto, y finaliza en el 100% al contactar al

100% . En contraste, la Regresión Logística inicia ligeramente mejor (38.8% al 10% de contacto), mantiene una pendiente constante y registra el 82.0% al 50% de contacto , también llegando al 100% al finalizar. Aunque ambos modelos son eficaces, la Regresión Logística presenta una ligera ventaja en tasas de conversión a porcentajes bajos de contacto, mientras que el Random Forest destaca con un inicio más agresivo.

La elección entre ambos modelos dependerá del objetivo específico. Si la prioridad es capturar la mayor cantidad de conversiones con un bajo esfuerzo (p. ej., contactar al 20% de la población), la Regresión Logística ofrece mejores resultados (61.6% vs. 60.4%). Sin embargo, si se busca un rápido incremento inicial para maximizar conversiones en fases tempranas, el Random Forest es más eficiente. Ambos modelos garantizan capturar todas las conversiones al contactar al 100% de la población , pero la Regresión Logística muestra mayor estabilidad y sostenibilidad en su rendimiento a medida que aumenta el tamaño de la muestra. Esto sugiere que, en contextos donde la precisión incremental es crítica, la Regresión Logística podría ser preferible, aunque las diferencias son mínimas y podrían no justificar cambios significativos en la implementación.


Curvas lift



Las curvas Lift comparan la eficacia de los modelos Random Forest y Regresión Logística en términos de ganancia predictiva respecto a una selección aleatoria (línea base). Ambos modelos superan ampliamente la línea base (lift = 1) en todas las porcentajes de población contactada, demostrando un claro valor predictivo. El modelo de Random Forest destaca inicialmente con un lift de 6 al contactar solo el 1% de la población, lo que indica que captura 6 veces más conversiones de lo esperado aleatoriamente. Sin embargo, su curva declina rápidamente, cayendo a un lift de ~3 al 20% de contacto y estabilizándose cerca de 1.5 para porcentajes superiores al 50%. Por otro lado, la Regresión Logística inicia ligeramente por debajo del Random Forest (lift ~5 al 1%), pero mantiene una caída más gradual.

Aunque ambos modelos son efectivos, el Random Forest ofrece una ventaja significativa en las primeras etapas (top 1-5% de la población), ideal para campañas enfocadas en maximizar conversiones con mínimos esfuerzos. La Regresión Logística, en cambio, presenta mayor estabilidad y sostenibilidad en su rendimiento a medida que se aumenta el tamaño de la muestra, lo que podría ser preferible en estrategias que requieran equilibrio entre alcance y precisión. Ambos superan ampliamente el rendimiento aleatorio, pero el Random Forest se impone en la capacidad de identificar rápidamente los casos más probables de conversión.

Curvas ROC



Las curvas ROC revelan que ambos modelos superan significativamente la línea base aleatoria (diagonal), demostrando su capacidad para distinguir entre clientes que suscriben y no suscriben depósitos. El Random Forest alcanza un AUC de 0.7832, mientras que la Regresión Logística registra un AUC ligeramente superior de 0.7972. Esto indica que, aunque ambos modelos son efectivos, la Regresión Logística tiene una ventaja marginal en la discriminación global entre clases, especialmente en rangos intermedios de probabilidad. La curva de la Regresión Logística muestra una pendiente más pronunciada inicialmente, lo que sugiere mayor sensibilidad para identificar verdaderos positivos con bajos falsos positivos en umbrales bajos, mientras que el Random Forest mantiene un equilibrio más estable entre TVP y TFP en rangos extremos.

A pesar de la ligera ventaja en AUC de la Regresión Logística, la elección del modelo debe considerar el objetivo específico de la campaña. Si el enfoque es maximizar el recall (como se priorizó durante el ajuste de hiperparámetros), el Random Forest podría ser preferible, ya que su curva ROC muestra un TPR más alto en umbrales altos (asociados a mayores probabilidades de conversión), lo que se alinea con la necesidad de capturar la mayor cantidad de clientes potenciales, incluso a costa de más falsos positivos. Por otro lado, la Regresión Logística, con su mayor AUC, es más adecuada si se busca un equilibrio entre discriminación y simplicidad, especialmente en escenarios donde la interpretabilidad de coeficientes es crítica para la toma de decisiones. Ambos modelos, sin embargo, validan la robustez del enfoque predictivo, con AUCs que superan ampliamente el umbral de 0.7, lo que refuerza su utilidad para guiar estrategias de marketing focalizadas.

Importancia de las variables

Random forest

FEATURE	IMPORTANCE
euribor3m	0.3001
emp.var.rate	0.2856
nr.employed	0.2252
cons.conf.idx	0.0727
pdays	0.0426
poutcome_success	0.0415
education_university.degree	0.0089
cons.price.idx	0.0054
poutcome_nonexistent	0.0047
campaign	0.0036
marital_single	0.0026
housing_unknown	0.0024
job_technician	0.0014
default_unknown	0.0013
loan_unknown	0.0013

Regresión logística

FEATURE	COEFICIENTE
emp.var.rate	-1.3613
contact_telephone	-1.0885
euribor3m	0.8396
cons.price.idx	0.7366
nr.employed	-0.5392
poutcome_nonexistent	0.5064
job_retired	0.4805
job_student	0.4572
poutcome_success	0.3287
default_unknown	-0.2604
pdays	-0.2594
education_university.degree	0.2410
education_basic.6y	0.2081
job_housemaid	-0.1757
marital_single	0.1638

Random Forest destaca variables macroeconómicas como las más influyentes: euribor3m (0.3001), emp.var.rate (0.2856) y nr.employed (0.2252). Estas reflejan el impacto del entorno económico en la decisión del cliente, con tasas de interés bajas y altos niveles de empleo asociados a mayores conversiones. Variables secundarias incluyen cons.conf.idx (0.0727) y pdays (0.0426), mientras que factores demográficos como education_university.degree (0.0089) tienen menor peso. La ausencia de variables de contacto en las primeras posiciones sugiere que el modelo prioriza indicadores externos sobre características operativas.

Regresión Logística revela patrones distintos: emp.var.rate (-1.3613) y contact_telephone (-1.0885) son los coeficientes más negativos, indicando que un mayor número de contactos telefónicos y una baja tasa de variación del empleo reducen la probabilidad de conversión. En contraste, euribor3m (0.8396) y cons.price.idx (0.7366) muestran relación positiva, alineándose con el análisis de Random Forest. Destaca poutcome_nonexistent (0.5064), que refuerza la importancia del historial previo: clientes sin interacción previa tienen menor probabilidad de suscribir. La dirección de los coeficientes permite interpretar estrategias, como priorizar contactos celulares (coeficiente positivo implícito en la ausencia de teléfono fijo).

Ambos modelos coinciden en la relevancia de euribor3m y emp.var.rate, validando su rol como predictores robustos. Sin embargo, Random Forest enfatiza el impacto colectivo de variables económicas, mientras Regresión Logística destaca la importancia de factores operativos como el canal de contacto. Esta divergencia refleja diferencias metodológicas: Random Forest captura interacciones no lineales entre variables, mientras la Regresión Logística ofrece una interpretación lineal directa. Para la campaña, esto implica que:

Variables económicas son críticas en ambos enfoques, reforzando la necesidad de ajustar estrategias según el contexto macroeconómico.

El canal de contacto (teléfono vs. celular) emerge como factor ajustable en la Regresión Logística, sugiriendo oportunidades para optimizar la logística de la campaña.

El historial previo (poutcome) es consistente en ambos modelos, subrayando la importancia de segmentar clientes según su respuesta a campañas anteriores.

Estos hallazgos respaldan un enfoque híbrido: usar Random Forest para identificar variables macroeconómicas clave y Regresión Logística para refinar tácticas operativas, maximizando así la efectividad de la campaña.

Conclusiones Finales

Resumen del Análisis

Este estudio analizó una campaña de marketing bancario para depósitos a plazo, identificando patrones clave en el comportamiento de los clientes y desarrollando modelos predictivos para optimizar futuras campañas. Los hallazgos principales incluyen:

1. **Perfil del cliente con alta conversión:** Jubilados (25%), estudiantes (20%) y universitarios (14.2%) muestran tasas excepcionales de suscripción.
2. **Factores económicos clave:** Bajas tasas de interés (euribor3m ~1%) y alto empleo (~5,100 empleados) aumentan significativamente la probabilidad de conversión.
3. **Patrones temporales críticos:** Marzo, septiembre y diciembre registran tasas de conversión 4-5 veces superiores al promedio (44-50%), mientras los jueves son el día más efectivo (12.1%).
4. **Variables operativas:** Contactos celulares y duraciones superiores a 200 segundos duplican la probabilidad de éxito.

Recomendaciones Estratégicas

- **Segmentación de Clientes**
 - **Priorizar:** Jubilados, estudiantes y titulados universitarios
 - **Evitar:** Jóvenes <30 años en empleos inestables o con préstamos personales

Optimización Temporal

- **Concentrar recursos** en marzo, septiembre y diciembre
- **Maximizar contactos los jueves** (día de mayor efectividad)
- **Limitar campañas** en mayo-julio (baja conversión a pesar de alto volumen)

Gestión de Contacto

- **Buscar interacciones >200 segundos** (3x más probabilidad de éxito)
- **Limitar intentos** por cliente (3-5 contactos por campaña)
- **Priorizar canal celular** sobre teléfono fijo

Implementación Modelos

1. **Random Forest para identificación temprana:** Usar en fases iniciales para capturar clientes de alta probabilidad
2. **Regresión Logística para optimización continua:** Emplear en etapas avanzadas por su estabilidad en muestras grandes
3. **Variables económicas como termómetro:** Monitorear euribor3m y nr.employed para ajustar estrategias

Limitaciones y Trabajo Futuro

- **Desafíos de datos:** 20.9% valores desconocidos en morosidad (default) y 4.2% en educación requieren estrategias de imputación avanzada
- **Validación en campo:** Implementar pruebas A/B con los segmentos identificados
- **Optimización de costos:** Desarrollar modelo de costo-beneficio para minimizar falsos positivos
- **Análisis de ciclo económico:** Profundizar en impacto de recesiones/expansiones en tasas de conversión

Impacto esperado: La implementación de estas recomendaciones podría incrementar la tasa de conversión y optimizar el costo por adquisición, maximizando el ROI de futuras campañas.